



LAPORAN PENELITIAN OPSI

**CLASSKINFY: Aplikasi Klasifikasi Penyakit Kulit dengan Kamera
Smartphone menggunakan Pemrosesan Citra dan Deep Learning**

Owen Tjandra

**Ilmu Pengetahuan Terapan
Ilmu Kesehatan dan Rekayasa Biomedis**

Cahaya Bangsa Classical School

Kabupaten Bandung Barat, Jawa Barat

Tahun 2025

Abstrak

Keterbatasan akses terhadap diagnosis dermatologi yang cepat dan akurat menjadi tantangan global, terutama di daerah terpencil. Proses diagnosis manual masih membutuhkan waktu lama dan rentan terhadap kesalahan subjektif. Penelitian ini bertujuan mengembangkan sistem deteksi dini penyakit kulit berbasis aplikasi smartphone yang mengintegrasikan pemrosesan citra dan deep learning untuk mengatasi masalah ini. Penelitian ini memiliki dua pendekatan utama, yaitu sistem prediksi awal berbasis analisis ΔE dan klasifikasi menggunakan Convolutional Neural Network (CNN) EfficientNet-B3. Pada tahap awal, citra lesi dianalisis menggunakan metode ΔE dalam ruang warna CIELAB untuk mendeteksi perbedaan warna antara kulit sehat dan jaringan lesi, dilanjutkan dengan ekstraksi fitur geometri, morfologi, serta warna untuk menghasilkan indikasi awal penyakit. Selanjutnya, model CNN EfficientNet-B3 digunakan untuk melakukan klasifikasi akhir. Dataset HAM10000, yang terdiri atas 10.015 gambar dermatoskopi tujuh kelas penyakit, digunakan untuk pelatihan dan evaluasi. Untuk mengatasi ketidakseimbangan data, diterapkan strategi *data augmentation* yang agresif serta *Cross Entropy Loss*. Hasil penelitian menunjukkan bahwa sistem mampu mendeteksi area lesi dengan akurat serta mengklasifikasikan tujuh jenis penyakit kulit utama dengan nilai akurasi rata-rata 96.2%, precision 95.8%, recall 95.3%, F1-score 95.5%, spesifisitas 98,1%, dan AUROC 96,6% yang konsisten di ketujuh kelas penyakit. Integrasi antara sistem prediksi awal dan CNN terbukti efektif dalam mempercepat proses diagnosis serta meningkatkan keandalan identifikasi penyakit kulit secara otomatis. Dengan demikian, penelitian ini berhasil membuktikan potensi sistem ini sebagai alat bantu diagnosis (computer-aided diagnosis) yang cepat dan efisien, serta berpotensi untuk diimplementasikan dalam aplikasi smartphone.

Kata Kunci: Klasifikasi Penyakit Kulit, Convolutional Neural Network (CNN), Segmentasi Lesi, Dataset HAM10000, Aplikasi Smartphone Dermatologi

BAB I. PENDAHULUAN

1.1 Latar Belakang

Penyakit kulit termasuk salah satu penyakit yang paling umum di seluruh dunia. Penyakit ini berkisar dari kondisi ringan seperti jerawat dan eksim, hingga kasus kanker yang mengancam jiwa seperti melanoma. Meskipun sudah ada pengobatan untuk penyakit-penyakit ini, masalah utama masih terletak pada kurangnya diagnosis dini akibat keterbatasan akses ke dokter kulit, tingginya biaya konsultasi, dan kurangnya kesadaran masyarakat. Banyak orang salah mendiagnosis atau bahkan mengabaikan kondisi kulit mereka karena tidak tersedianya alat diagnosis yang memadai.

Urgensi diagnosis dini sangatlah penting. Hal ini terutama berlaku untuk penyakit seperti basal cell carcinoma, melanoma, actinic keratosis, dan lainnya. Melanoma (MEL), sejenis kanker, jika terdeteksi lebih awal, dapat menghasilkan tingkat kelangsungan hidup yang tinggi. Jika tidak, kanker tersebut seringkali bermetastasis dan membuat prosedur pengobatan menjadi lebih sulit. Basal Cell Carcinoma (BCC) adalah kanker kulit yang tumbuh lambat tetapi bisa merusak jaringan di sekitarnya jika tidak ditangani dengan cepat. Sementara itu, Actinic Keratosis (AKIEC) adalah lesi prakanker yang dapat berkembang menjadi karsinoma sel skuamosa bila diabaikan. Ketiga penyakit kulit ini, yang akan diselidiki lebih lanjut, menunjukkan betapa pentingnya deteksi dini. Turut serta menangani masalah ini dapat menyelamatkan nyawa, mengurangi biaya perawatan kesehatan, dan meningkatkan kesejahteraan masyarakat.

Menurut WHO, diperkirakan 900 juta orang di seluruh dunia menderita penyakit kulit, dengan melanoma saja menyebabkan 57.000 kematian. Di daerah pedesaan, diagnosis profesional terhadap penyakit kulit sangat minim. Rasio dokter kulit terhadap pasien bisa serendah 1 dokter untuk 100.000 orang. Hal ini dapat mendorong pasien untuk mendiagnosis diri sendiri, yang sering kali berujung pada salah diagnosis dan dapat berkembang menjadi infeksi berat, seperti peradangan kronis, atau bahkan kasus mengancam nyawa seperti melanoma metastatik. Studi menunjukkan bahwa deteksi dini dapat meningkatkan tingkat kelangsungan hidup hingga 99%, tetapi pada deteksi tahap lanjut di mana penyakit telah menyebar ke seluruh tubuh, tingkat kelangsungan hidup menurun secara signifikan. Ini berarti dibutuhkan sistem deteksi awal yang lebih terjangkau, mudah diakses, dan akurat untuk mengatasi masalah ini.

Solusi yang ada saat ini untuk mendeteksi penyakit kulit sebagian besar bergantung pada konsultasi klinis. Metode tradisional, dokter kulit memeriksa kulit pasien secara langsung, biasanya dengan alat khusus seperti dermatoskop. Ada juga teknik diagnostik canggih seperti biopsi dan mikroskopi konfokal. Namun, masalah utama tetap terletak pada deteksi dini penyakit-penyakit kulit ini. Alat diagnosis profesional sering kali sangat mahal dan memerlukan spesialis terlatih. Dokter dan dokter kulit ini mayoritas bekerja di area dengan fasilitas kesehatan perkotaan yang memadai, sehingga pasien di daerah terpencil dengan akses terbatas ke diagnosis yang tepat jadi terpinggirkan. Salah diagnosis sendiri atau keterlambatan tindakan untuk mencari bantuan medis bisa menjadi salah satu konsekuensi.

Kami mengusulkan sebuah Aplikasi Klasifikasi Penyakit Kulit dengan Kamera Smartphone menggunakan Pemrosesan Citra dan Deep Learning yang praktis untuk smartphone dan memungkinkan pengguna memotret kelainan kulit dan menerima penilaian berbasis AI secara cepat langsung di perangkat mereka. Aplikasi ini meningkatkan kualitas gambar dengan mengurangi noise, menyeimbangkan warna, dan menandai batas lesi, lalu memproses foto tersebut melalui machine learning yang dilatih menggunakan gambar-gambar melanoma, basal cell carcinoma, actinic keratosis, dan lainnya yang telah diverifikasi oleh dokter kulit. Aplikasi akan menampilkan kondisi yang paling mungkin, sorotan visual pada area yang dianalisis, dan saran sederhana seperti memantau bintik

tersebut atau berkonsultasi dengan dokter kulit. Dengan mengkombinasikan kamera smartphone yang familiar dengan AI yang telah teruji, aplikasi ini bertujuan memudahkan pemeriksaan kulit dini dan andal bagi siapa saja, terutama di tempat di mana perawatan spesialis sulit dijangkau.

1.2 Rumusan Masalah

Proposal Penelitian ini dibatasi oleh rumusan masalah:

1. Bagaimana merancang dan mengimplementasikan sistem deteksi dini penyakit kulit berbasis smartphone dengan akurasi tinggi?
2. Bagaimana mengoptimalkan model CNN agar mampu menangani variabilitas citra dermatologis dan meminimalkan kesalahan klasifikasi?

1.3 Tujuan Penelitian

Proposal Penelitian ini memiliki tujuan masalah

1. Menilai efektivitas penerapan pipeline dermatologis berbasis smartphone dalam mendukung deteksi dini penyakit kulit.
2. Mengevaluasi dan mengembangkan strategi optimasi model CNN untuk meningkatkan ketahanan klasifikasi terhadap variasi kondisi pencitraan.

1.4 Manfaat Penelitian

Mengklasifikasikan penyakit kulit menggunakan ponsel dan deep learning memberikan diagnosa yang mudah diakses, hemat biaya, dan real-time, terutama untuk area yang kurang terlayani dengan akses kesehatan yang terbatas. Ini dapat membuat pengguna mendeteksi kondisi lebih awal, mengurangi beban pada sistem perawatan kesehatan, sekaligus meningkatkan akurasi model pembelajaran mendalam untuk menyaingi diagnosis profesional.

BAB II. TINJAUAN PUSTAKA

2.1 Skin Diseases

Kumpulan data sekunder dari dataset HAM10000 berisi 7 jenis penyakit kulit, mulai dari kondisi jinak hingga ganas. Kumpulan data ini mencakup 10.015 gambar dermatoskopi yang dirancang untuk pembelajaran mesin. Gambar-gambar tersebut dikumpulkan dari berbagai populasi, sehingga menciptakan kumpulan data yang beragam. Kumpulan data ini terdiri dari sekitar 2,6 GB gambar dan metadata tambahan. Penyakit-penyakit tersebut diklasifikasikan ke dalam MEL, BCC, AKIEC, BKL, DF, NV, dan VASC.

2.1.1 Melanoma Skin Cancer (MEL)

Melanoma (MEL) adalah bentuk kanker kulit yang paling agresif, berasal dari melanosit dan bertanggung jawab atas sebagian besar kematian akibat kanker kulit meskipun insidensinya relatif rendah (Ahmed dkk., 2020). Patogenesisnya terkait dengan mutasi pada gen seperti BRAF, NRAS, KIT, GNAQ, dan GNA11, serta mekanisme penghindaran imun yang dimediasi oleh overexpresi PD-L1 (Cui dkk., 2024). Secara klinis, deteksi dini bergantung pada kriteria ABCDE (asimetri, batas tidak teratur, variasi warna, diameter >6 mm, dan perubahan), serta tanda “ugly duckling” dan gejala seperti ulserasi, perdarahan, atau lesi yang tidak sembuh (NHS, 2023; Duarte dkk., 2021). Prognosis bergantung pada stadium: eksisi bedah dini seringkali kuratif, sedangkan penyakit stadium lanjut menunjukkan potensi metastasis tinggi, survival buruk (<25% pada stadium IV), dan memerlukan terapi sistemik mahal seperti inhibitor titik kontrol imun (Domingues et al., 2018). Deteksi dini sangat penting untuk meningkatkan survival (>90% pada stadium awal) dan mengurangi beban pengobatan.

2.1.2 Basal Cell Carcinoma (BCC)

Karsinoma Sel Basal (BCC) adalah jenis kanker kulit yang paling umum, mewakili sekitar 80% dari semua kanker kulit non-melanoma (Peris dkk., 2019). Kanker ini berasal dari sel keratinosit basal, dengan gangguan pada jalur sinyal hedgehog (PTCH1, SMO, SUFU) yang menyebabkan proliferasi tidak terkendali (Sekulic dkk., 2008). Faktor risiko utama adalah paparan ultraviolet kronis, meskipun tipe kulit terang dan sindrom genetik seperti Gorlin-Goltz juga meningkatkan kerentanan. Meskipun BCC jarang metastasis (<0,1%), ia bersifat invasif lokal dan dapat menyebabkan kerusakan jaringan yang signifikan, terutama di area berisiko tinggi seperti wajah. Subtipe meliputi nodular (papul berkilau dengan tepi melengkung), superficial (plak eritematosus dan bersisik), dan morpheaform (seperti bekas luka, infiltratif). Diagnosis banding dengan melanoma berpigmen memerlukan konfirmasi histopatologis. Eksisi dini umumnya menghasilkan hasil yang baik, sedangkan penemuan terlambat mungkin memerlukan intervensi bedah atau radioterapi yang luas.

2.1.3 Actinic Keratoses and Intraepithelial Carcinoma (AKIEC)

Keratosis Aktinik (AK), sering diklasifikasikan sebagai Keratosis Aktinik dengan Karsinoma Intraepitel (AKIEC), merupakan lesi prakanker keratinositik yang umum terjadi akibat paparan ultraviolet kronis dan mutasi pada gen penekan tumor seperti TP53 (Siegel et al., 2020). Lesi ini muncul sebagai makula atau papula eritematosus dan bersisik pada kulit yang terpapar sinar matahari, kadang-kadang disertai iritasi lokal. Tanpa pengobatan, hingga 16% kasus dapat berkembang menjadi karsinoma sel skuamosa invasif setiap tahun (Marks dkk., 1988). Variasi klinis meliputi AK hipertrofik, atrofik, berpigmen, bowenoid, dan aktinik cheilitis, masing-masing dengan ciri morfologis yang khas. Strategi pengelolaan mencakup krioterapi, kemoterapi topikal (5-fluorouracil), imunomodulator (imiquimod), terapi

fotodinamik, atau prosedur bedah, tergantung pada beban lesi. Diagnosis yang akurat sangat penting, karena AKIEC dapat menyerupai keratosis jinak dan entitas ganas seperti melanoma.

2.1.4 Benign Keratosis (BKL)

Benign Keratosis (BKL) merupakan kelompok heterogen lesi keratinositik non-malignant, termasuk seborrheic keratosis, *solar lentigo*, dan *lichen planus-like keratosis*. Meskipun secara biologis tidak agresif dan tidak memiliki potensi metastasis, lesi-lesi ini sering menyerupai neoplasma ganas, terutama BCC berpigmen atau melanoma, sehingga memerlukan kehati-hatian dalam diagnosis. Keratosis seborrheic biasanya muncul sebagai plak verukosa dengan batas yang tajam dan morfologi “terpasang”; lentigo solar adalah makula datar dengan pigmen merata yang terkait dengan kerusakan akibat sinar matahari; dan keratosis serupa lichen planus menunjukkan pigmen tidak teratur akibat peradangan. Intervensi terapeutik umumnya tidak diperlukan, meskipun krioterapi, kuretase, atau ablasi laser dapat dilakukan untuk alasan simptomatis atau kosmetik. (Scholz et al., 2020)

2.1.5 Dermatofibroma (DF)

Dermatofibroma (DF) adalah lesi fibrohistiokistik jinak yang umum terjadi pada dermis, sering kali berkembang setelah trauma ringan seperti gigitan serangga atau folikulitis. Secara klinis, DF muncul sebagai nodul yang keras dan berbentuk kubah, sering ditemukan pada ekstremitas bawah, dengan tanda khas “dimple sign” saat ditekan secara lateral. Secara histologis, lesi ini terdiri dari fibroblas dan histiosit dalam pola storiform, disertai dengan hiperplasia epidermis di atasnya. Varian meliputi subtipo aneurismal, seluler, hemosiderotik, dan lipid, beberapa di antaranya menyerupai lesi vaskular atau melanoma. Meskipun secara biologis jinak dan umumnya asimtomatis, DF dapat diangkat untuk kepastian diagnostik atau pengurangan gejala. Perbedaan dari melanoma dan dermatofibrosarcoma protuberans sangat penting untuk menghindari pengobatan berlebihan. (Requena & Sangüeza, 1995)

2.1.6 Melanocytic Nevus (NV)

Nevus Melanositik (NV), atau tahi lalat, adalah pertumbuhan jinak sel melanosit dan merupakan lesi kulit berpigmen paling umum pada manusia. Pembentukannya dipengaruhi oleh predisposisi genetik dan paparan ultraviolet kumulatif, dengan sebagian besar individu memiliki 10–40 nevi. Klasifikasi didasarkan pada kedalaman histologis: junctional (epidermal), compound (epidermal dan dermal), intradermal (dermal), dan bentuk kongenital. Meskipun sebagian besar tidak berbahaya, nevi displastik menunjukkan fitur atipikal seperti asimetri, batas yang tidak teratur, dan variasi warna, yang meningkatkan risiko melanoma. Pemantauan klinis menggunakan aturan ABCDE (A untuk Asimetri, B untuk Ketidakteraturan tepi, C untuk Perbedaan warna, D untuk Diameter lebih besar dari 6 mm (sekitar ukuran penghapus pensil), dan E untuk Tahi lalat yang berkembang atau berubah) sangat penting, meskipun pengobatan umumnya tidak diperlukan kecuali ada kecurigaan transformasi ganas. (Bodman, et al. 2025)

2.1.7 Vascular Lesions (VASC)

Lesi Vaskular (VASC) mencakup spektrum malformasi vaskular jinak atau proliferasi, baik kongenital maupun didapat. Lesi ini muncul sebagai makula, papula, atau nodul berwarna merah hingga ungu, tergantung pada jenis pembuluh darah dan kedalamannya. Entitas umum meliputi angioma ceri (papula kecil berbentuk kubah yang terkait usia), angiokeratoma (papula vaskular dengan hiperkeratosis), hemangioma infantil (lesi proliferatif yang akhirnya regresi), dan granuloma piogenik (nodul yang tumbuh cepat, rapuh, dan rentan berdarah). Meskipun umumnya asimtomatis, lesi ini dapat menimbulkan masalah kosmetik atau fungsional, terutama di daerah anatomi yang sensitif. Pengobatan bersifat opsional dan

dapat melibatkan ablati laser, krioterapi, elektrokauter, atau eksisi bedah jika secara klinis diindikasikan. (Brahmbhatt, 2020)

2.2 Pengolahan Gambar dan *Computer Vision*

Klasifikasi penyakit kulit yang akurat pada gambar bergantung pada sebuah pipeline yang pertama-tama membersihkan dan menstandarkan foto mentah, lalu mengekstrak ciri diskriminatif berupa warna, tekstur, dan bentuk, dan akhirnya memisahkan, lalu menggambar batas dengan presisi, area yang sakit agar pengklasifikasi hanya melihat piksel yang relevan (IBM, 2025). Filter pengurangan noise menekan artefak sensor yang bisa menyerupai lesi, peningkatan kontras dan normalisasi warna memperlihatkan perubahan pigmen halus dan menjamin bahwa fitur berbasis warna dapat dibandingkan antar-gambar, deskriptor tepi, tekstur, dan warna mengubah piksel yang telah diproses menjadi angka yang dapat dipelajari model, lalu segmentasi berbasis region memisahkan lesi dari latar belakang kulit, dan deteksi kontur menyempurnakan batas, menghasilkan pengukuran seperti luas, asimetri, dan ketidakteraturan tepi. Keseluruhan tahap ini meningkatkan rasio sinyal-terhadap-noise, mengurangi variabilitas dataset, dan menyediakan peta fitur berkualitas tinggi yang terpusat pada lesi, yang semuanya berujung pada diagnosis yang lebih andal dan akurat oleh model machine-learning klasik atau deep-learning.

1. Contrast Enhancement: Contrast enhancement (histogram equalisation, CLAHE) memperluas perbedaan terang-gelap secara lokal sehingga lesi gelap pada kulit cerah atau plak merah pada kulit gelap terlihat lebih jelas (IBM, 2025).
2. Color Normalization: Color normalization (white-balance, gray-world, deep-learning colour-transfer) menstandarkan warna setiap gambar ke ruang warna yang sama (misalnya CIELAB) agar fitur warna—seperti blue-white veil atau sisik kuning—konsisten di seluruh dataset (IBM, 2025).
3. Edge Detection: Edge detection (Sobel, Prewitt, Canny) menyorot perubahan intensitas tajam untuk memperkirakan batas lesi, memudahkan perhitungan metrik bentuk seperti asimetri dan ketidakteraturan tepi (Marr & Hildreth, 1980).
4. Texture Analysis: Texture analysis (GLCM, LBP, wavelet) menerjemahkan pola permukaan menjadi vektor numerik, kontras atau homogenitas, untuk membedakan motif seperti sisik eksim, likenifikasi atopik, atau jaringan pigmen melanoma (Terashima, 2002; Bino et al., 2012; Sedaghatjoo et al., 2024).
5. Color Analysis: Color analysis (histogram warna, dominant-hue, chromatic moments) menangkap distribusi dan variasi pigmen di ruang HSV atau CIELAB, penting untuk mengenali melanoma multicolor, lesi lupus kebiruan, atau kerak kuning pada impetigo (Sharma & Nayyer, 2015).
6. Region-Based Segmentation: Metode thresholding (pada saluran warna atau tekstur), region-growing, watershed, atau, dalam pipeline deep, CNN gaya U-Net memotong gambar menjadi lesi dan latar belakang (IBM, 2025). Masking yang akurat membatasi komputasi fitur hanya ke area kulit yang sakit, mengecualikan rambut atau penggaris yang mengganggu, serta menyediakan region of interest yang ingin diperiksa klinisi.
7. Contour Detection: Setelah segmentasi, model active-contour (snake) atau penggabungan tepi morfologis mengikuti garis kontur lesi secara kontinu (D. Yang et al., 2022). Kontur yang disempurnakan ini memberi metrik geometris (luas, kepadatan, dimensi fraktal) dan memungkinkan pemotongan otomatis untuk input pengklasifikasi atau pemantauan longitudinal evolusi lesi.

2.3 Machine Learning dalam Klasifikasi Gambar

Sistem machine-learning (ML) dan deep-learning (DL) mengklasifikasikan citra penyakit kulit dengan terlebih dahulu mempelajari pola dari dataset berlabel, kemudian memprediksi kategori foto baru. Algoritma ML tradisional, seperti Random Forests, yang menggabungkan banyak pohon keputusan (decision tree) dan tahan terhadap over-fitting, bergantung pada fitur warna, tekstur, dan bentuk yang dirancang secara manual dari gambar, sedangkan DL, sebagai bagian dari ML, menggunakan arsitektur Neural Network atau jaringan saraf tiruan berlapis (misalnya CNN, ResNet, Inception) untuk mempelajari fitur-fitur tersebut langsung dari piksel mentah (Zhou, 2021; IBM, 2025). Transfer-learning mempercepat pengembangan dengan mem-fine-tune CNN besar yang sudah dilatih sebelumnya (seperti VGG atau ResNet) pada dataset dermatologi yang relatif kecil (Hosna et al., 2022). Keberhasilan pelatihan model bergantung pada ketersediaan gambar beragam dan berlabel baik, data-augmentation (rotasi, flip, perubahan pencahayaan, pergeseran perspektif 3-D) untuk mengatasi sampel terbatas, dan optimisasi iteratif yang meminimalkan fungsi loss (Tableau, 2025). Kualitas model dipantau pada set validasi terpisah dan akhirnya dinilai pada test set yang belum pernah dilihat sebelumnya menggunakan metrik akurasi, presisi, recall, dan loss (Larsen et al., 2002). Model dengan performa terbaik kemudian diintegrasikan dan diuji dalam alur kerja produksi (misalnya aplikasi kamera ponsel) untuk memastikan kemampuan menangani variasi dunia nyata dalam pencahayaan, resolusi, dan latar belakang sebelum penerapan klinis (IBM, 2025).

2.4 Convolutional Neural Network

Jaringan Saraf Konvolusional (CNN) adalah arsitektur pembelajaran mendalam yang dirancang untuk memproses data berstruktur grid seperti gambar dengan meniru sistem visual manusia. Keunggulan utamanya terletak pada penggunaan lapisan konvolusional, yang menerapkan filter untuk mendeteksi fitur tingkat rendah seperti tepi, tekstur, dan bentuk, serta secara bertahap menggabungkannya menjadi pola tingkat tinggi seperti objek atau lesi medis. Lapisan pooling mengurangi kompleksitas data sambil mempertahankan informasi esensial, dan aktivasi nonlinier seperti ReLU memungkinkan jaringan untuk memodelkan hubungan kompleks. Pembelajaran fitur hierarkis ini memungkinkan CNN untuk secara langsung memetakan nilai piksel mentah ke output klasifikasi, menghilangkan kebutuhan akan ekstraksi fitur buatan tangan yang digunakan dalam pendekatan pembelajaran mesin tradisional. Bersama dengan teknik seperti normalisasi batch, dropout, dan klasifikasi softmax, CNN telah menjadi fondasi aplikasi penglihatan komputer modern, mulai dari deteksi objek hingga analisis gambar medis.

Dalam dermatologi, Jaringan Saraf Tiruan Konvolusional (CNN) telah banyak diterapkan untuk klasifikasi lesi kulit menggunakan dataset seperti HAM10000. Dengan mendeteksi secara otomatis petunjuk visual seperti asimetri, batas yang tidak teratur, dan variasi warna, CNN dapat membedakan antara lesi jinak dan ganas dengan akurasi mendekati tingkat keakuratan dokter kulit. Keluwesan arsitektur seperti ResNet, DenseNet, dan EfficientNet memungkinkan CNN untuk menangani variasi ukuran, tekstur, dan pencahayaan lesi. Dengan dukungan dataset berskala besar yang ter anotasi dan akselerasi GPU, sistem berbasis CNN menunjukkan potensi besar untuk dukungan pengambilan keputusan klinis, meningkatkan deteksi dini dan hasil pengobatan pasien dalam diagnosis kondisi seperti melanoma.

2.5 Python dan Pytorch

Python adalah bahasa pemrograman tingkat tinggi yang banyak digunakan untuk mengembangkan berbagai jenis aplikasi. Bahasa ini memiliki beragam penerapan, mulai dari machine learning, kecerdasan buatan, pengembangan web, hingga komputasi ilmiah (Oliphant, 2007). Python merupakan bahasa pemrograman pilihan utama untuk ilmu data, machine learning, dan kecerdasan buatan karena sintaksnya yang sederhana dan mudah dibaca. Di dalam Python, terdapat framework deep learning bernama PyTorch, yang awalnya dikembangkan oleh laboratorium riset AI milik

Facebook dan kini dikelola oleh PyTorch Foundation. PyTorch menyediakan sistem komputasi dinamis, yang berarti jaringan saraf (neural network) dapat dimodifikasi secara langsung selama program berjalan (runtime). Hal ini membuat PyTorch menjadi intuitif dan fleksibel bagi para pengembang.

Operasi tensor dalam PyTorch mirip dengan array pada NumPy, namun dilengkapi dengan dukungan akselerasi GPU melalui CUDA, sehingga memungkinkan komputasi yang lebih efisien di GPU. Pustaka ini juga mencakup API tingkat tinggi seperti `torch.nn`, `torch.optim`, dan `torchvision`, serta memberikan kendali tingkat rendah bagi pengguna yang ingin melakukan pengaturan lanjutan.

2.6 FastAPI dan Uvicorn

Selain untuk pengembangan model deep learning, Python juga akan digunakan sebagai bahasa utama dalam pengembangan sisi backend proyek ini. Framework FastAPI dipilih karena kemampuannya dalam membangun RESTful API yang cepat, efisien, dan mudah diintegrasikan dengan model machine learning. FastAPI memungkinkan pembuatan endpoint untuk menerima dan memproses input gambar secara real-time, yang kemudian akan diteruskan ke model klasifikasi berbasis PyTorch. Untuk menjalankan aplikasi secara lokal maupun dalam lingkungan produksi, akan digunakan Uvicorn, yaitu server ASGI (Asynchronous Server Gateway Interface) berperforma tinggi yang mendukung eksekusi asynchronous.

2.7 React

React adalah perpustakaan JavaScript modern yang dikembangkan oleh Meta (sebelumnya Facebook) dan banyak digunakan untuk membangun antarmuka pengguna dinamis dan interaktif dalam aplikasi web. Arsitektur berbasis komponennya memungkinkan pengembang untuk membangun elemen modular dan dapat digunakan kembali, sementara sistem rendering efisinya, yang didukung oleh Virtual DOM, memastikan bahwa hanya bagian-bagian antarmuka yang diperlukan yang diperbarui saat terjadi perubahan. Desain ini tidak hanya meningkatkan kinerja tetapi juga meningkatkan skalabilitas, menjadikan React pilihan yang disukai untuk aplikasi yang memerlukan interaksi responsif dan ramah pengguna.

React berfungsi sebagai kerangka kerja front-end yang menghubungkan pengguna dengan sistem klasifikasi penyakit kulit yang didukung oleh jaringan saraf konvolusional (CNN). Sementara CNN, yang diimplementasikan dalam PyTorch, melakukan tugas komputasi ekstraksi fitur dan klasifikasi lesi, React menyediakan antarmuka dimana pengguna dapat mengunggah gambar, melihat hasil klasifikasi, dan menafsirkan output model seperti skor probabilitas atau metrik kinerja. Dengan mengintegrasikan React ke dalam sistem, proyek ini menjembatani algoritma deep learning canggih dengan visualisasi berbasis web yang mudah diakses, sehingga memfasilitasi aplikasi praktis dalam diagnostik medis dan meningkatkan kemudahan penggunaan bagi klinisi, peneliti, dan pasien.

2.6 NEON

NEON adalah platform database terkelola (managed database service) berbasis PostgreSQL yang dirancang untuk aplikasi modern, dengan arsitektur pemisahan storage dan compute yang memungkinkan skalabilitas dan efisiensi biaya melalui fitur autoscaling dan autosuspend (Neon, 2024). Dalam penelitian ini, NEON berperan sebagai backend database yang andal untuk menyimpan semua data terstruktur aplikasi, termasuk metadata pengguna, riwayat prediksi, hasil klasifikasi, dan log sistem. Integrasi NEON ke dalam arsitektur menjamin konsistensi penyimpanan data transaksional dari aplikasi React dan API FastAPI, sekaligus mendukung analisis berkelanjutan, pelacakan riwayat, dan peningkatan model di masa depan melalui fitur branching untuk pengelolaan lingkungan pengembangan dan produksi yang terstruktur (Neon, 2025).

BAB III. METODE PENELITIAN

3.1 Waktu dan Tempat Penelitian

Waktu Penelitian: Mei - Oktober 2025

Tempat Penelitian: Cahaya Bangsa Classical School

3.2 Alat dan Bahan

1. Kamera Smartphone
2. Smartphone
3. Dataset Penyakit Kulit HAM 10000
4. Laptop Programming
5. Bahasa Pemrograman Python dan React-native
6. Server NEON

3.3 Perancangan dan Prosedur Penelitian

Prototipe penelitian ini dirancang sebagai pipeline berbasis Python/PyTorch yang menerima foto dermatologis mentah, meningkatkan dan menstandarkannya, lalu mengklasifikasikan setiap gambar ke dalam kategori penyakit kulit yang bermakna secara klinis. Di front end, antarmuka grafis ringan (desktop atau mobile) memungkinkan pengguna mengambil atau mengunggah foto; di back end, model convolutional-neural-network (CNN), yang di-fine-tune dari arsitektur pre-trained EfficientNet, menjalankan seluruh alur kerja mulai dari preprocessing hingga prediksi. Kami mengharapkan perangkat lunak ini dapat (i) memproses gambar dari berbagai kamera dan kondisi pencahayaan dengan input minimal dari pengguna, (ii) mendapatkan diagnosis akurat dan skor kepercayaan dalam waktu kurang dari dua detik pada perangkat keras konsumen, dan (iii) mencatat hasil yang dianonimkan untuk peningkatan model berkelanjutan dan keamanan privasi pengguna.

1. Data Preprocessing

Pra-pemrosesan data merupakan tahap penting dalam menyiapkan data sebelum digunakan untuk melatih model, dengan tujuan memastikan data yang bersih, konsisten, dan representatif sehingga proses pembelajaran menjadi lebih efektif (Tableau, 2025). Dalam konteks citra medis, tahap ini mencakup pemrosesan gambar seperti pengurangan noise, peningkatan kontras, pengubahan ukuran, serta normalisasi warna untuk menstandarkan input. Selain itu, dilakukan pula augmentasi data, yaitu teknik yang secara artifisial memperluas dan memperkaya dataset melalui transformasi seperti rotasi, flipping, penskalaan, pemotongan (cropping), serta penyesuaian warna yang meliputi kecerahan, saturasi, hue, maupun kondisi pencahayaan. Pendekatan yang lebih lanjut dapat mencakup penambahan noise atau deformasi elastis untuk meningkatkan variasi data. Dengan demikian, augmentasi tidak hanya berguna ketika jumlah data terbatas, tetapi juga berperan penting dalam meningkatkan ketahanan model terhadap overfitting dan memperkuat kemampuan generalisasi terhadap pola citra yang beragam.

2. Model Development

Model yang digunakan dalam penelitian ini adalah EfficientNet-B3, sebuah arsitektur CNN yang mengoptimalkan keseimbangan antara akurasi dan efisiensi melalui pendekatan compound scaling (Tan & Le, 2019). EfficientNet-B3 dipilih karena pendekatan compound scaling-nya yang menyeimbangkan kedalaman, lebar, dan resolusi jaringan, yang akurasi tinggi dengan efisiensi komputasi. Arsitektur dimodifikasi dengan mengganti lapisan classifier agar sesuai dengan tujuh kelas penyakit kulit dalam dataset HAM10000. Untuk mengatasi ketidakseimbangan kelas, digunakan *class*

weighting pada fungsi *Cross-Entropy Loss* dengan label smoothing (0,05), sementara optimisasi dilakukan menggunakan AdamW dengan learning rate awal 1e-4 yang disesuaikan adaptif menggunakan ReduceLROnPlateau. Stabilitas pelatihan dijaga dengan gradient clipping (ambang 2.0) dan *mixed precision training* pada GPU, serta early stopping untuk mencegah overfitting. Augmentasi citra (flip, rotasi, dan color jitter) serta normalisasi berdasarkan parameter ImageNet diterapkan pada resolusi 300×300 piksel guna meningkatkan generalisasi. Evaluasi dilakukan dengan validasi stratifikasi sebesar 20% menggunakan metrik akurasi, precision, recall, F1-score, confusion matrix, dan kurva ROC.

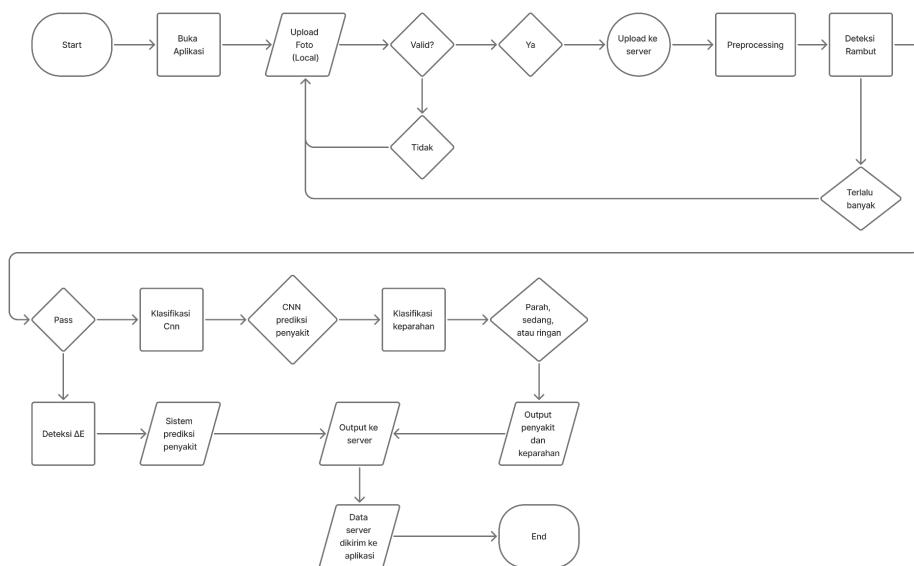
3. App Development

Aplikasi ini dirancang sebagai pipeline berbasis Python/PyTorch yang menerima foto dermatologis mentah, memprosesnya melalui tiga tahap inti, dan mengembalikan hasil klasifikasi. Di *front-end*, antarmuka grafis yang dibangun dengan React memungkinkan pengguna mengambil atau mengunggah foto. Di *back-end*, yang dijalankan oleh server FastAPI, gambar diproses oleh sistem prediksi awal (berbasis ΔE), kemudian oleh model CNN EfficientNet-B3 yang telah *fine-tune* dan data tersebut disimpan di NEON.

Sistem ini diimplementasikan menggunakan arsitektur *client-server* untuk menyeimbangkan kecepatan dan akurasi.

1. **Client-side (React App):** Bertugas untuk menangkap/mengunggah gambar, menampilkan hasil prediksi awal dari sistem ΔE secara instan, dan mengirimkan gambar ke *server* untuk analisis mendalam oleh CNN.
2. **Server-side (FastAPI + PyTorch):** Menampung model CNN yang lebih kompleks dan memproses permintaan dari *client*. Pendekatan ini memungkinkan penggunaan model yang lebih besar dan komputasi yang lebih berat tanpa membebani perangkat *smartphone* pengguna, sekaligus memudahkan pembaruan model.
3. **Penyimpanan Data (NEON):** Berfungsi sebagai SSoT (*single source of truth*) untuk semua data transaksional aplikasi. Arsitektur serverless NEON memastikan ketersediaan dan konsistensi data, sekaligus mengoptimalkan biaya penyimpanan.

3.4 Alur Kerja Sistem Klasifikasi



Gambar 1. Flowchart Alur Kerja Sistem

1. Tahap Input dan Validasi

Pengguna mengunggah foto kulit melalui aplikasi. Foto tersebut kemudian divalidasi terlebih dahulu agar sesuai standar (misalnya jelas, tidak buram, dan memenuhi ukuran minimum). Jika tidak valid, pengguna diminta mengunggah ulang.

2. Tahap Preprocessing

Gambar yang sudah valid diproses lebih lanjut untuk membersihkan gangguan visual, seperti rambut, noise, atau pencahayaan yang berlebihan. Tahap ini penting agar informasi visual yang masuk ke sistem lebih murni dan mudah dianalisis.

3. Deteksi Awal (Warna & Bentuk)

Sistem melakukan analisis visual awal dengan mendeteksi warna kulit, pola, dan bentuk. Hasil analisis ini menghasilkan prediksi awal mengenai kemungkinan jenis penyakit kulit. Metode ini cepat dan intuitif, tetapi kurang akurat jika digunakan sendiri.

4. Klasifikasi CNN

Foto yang sama juga diproses menggunakan Convolutional Neural Network (CNN). CNN dilatih dengan dataset gambar penyakit kulit asli, sehingga mampu mengenali pola kompleks yang tidak bisa ditangkap dengan analisis sederhana. CNN akan mengklasifikasikan gambar ke dalam salah satu dari tujuh jenis penyakit kulit yang sudah ditentukan.

5. Perbandingan dan Penggabungan Hasil

Hasil dari deteksi visual (warna & bentuk) dibandingkan dengan hasil CNN. Jika keduanya serupa, tingkat kepercayaan sistem meningkat. Jika berbeda, sistem memberikan prioritas pada hasil CNN karena berbasis pembelajaran dari data nyata.

6. Output Hasil Akhir

Sistem memberikan keluaran berupa:

- Jenis penyakit kulit yang terdeteksi
- Tingkat keparahan (ringan, sedang, parah).
- Informasi ini kemudian dikirim kembali ke aplikasi agar pengguna bisa langsung melihat prediksi

3.5 Analisis Data dan Evaluasi

Setelah CNN dilatih sepenuhnya, model diuji pada 15% data terpisah yang belum pernah dilihat sebelumnya. Metrik kunci seperti akurasi, presisi, recall, spesifisitas, skor F1, AUROC, dan matriks kebingungan dihitung untuk mengevaluasi performa dan mengidentifikasi masalah, misalnya salah mengklasifikasikan dermatofibroma atau melanoma. Hasil-hasil ini kemudian ditampilkan pada dashboard langsung menggunakan alat seperti TensorBoard dan Plotly, yang memantau performa seiring waktu dan menandai masalah, contohnya jika suatu kelas memiliki skor F1 di bawah 0,90. Heatmap Grad-CAM juga dihasilkan untuk menunjukkan area mana pada gambar yang menjadi fokus model, sehingga dokter kulit dapat memberikan umpan balik atas kesalahan, membantu mengidentifikasi dan memperbaiki kelemahan seperti kesulitan menangani variasi nada kulit atau kondisi pencahayaan tertentu.

$$Precision = \frac{\sum_{i=1}^l tp_i}{\sum_{i=1}^l (tp_i + fp_i)}. \quad Recall = \frac{\sum_{i=1}^l tp_i}{\sum_{i=1}^l (tp_i + fn_i)}.$$

$$F1 Score = \frac{(\beta^2+1) Precision \cdot Recall}{\beta^2 Precision + Recall}. \quad Specificity = \frac{\sum_{i=1}^l tn_i}{\sum_{i=1}^l (tn_i + fp_i)}.$$

BAB IV. HASIL DAN PEMBAHASAN

4.1 Hasil Sistem Prediksi Awal Berbasis Ekstraksi Fitur

Sebagai pelengkap sistem utama berbasis CNN, penelitian ini juga mengembangkan sistem prediksi awal yang berfungsi untuk memberikan hasil prediksi sementara sebelum CNN menyelesaikan proses inferensinya. Sistem ini menggunakan pendekatan klasifikasi berbasis fitur visual (feature-based classification), yang diperoleh melalui serangkaian tahapan pemrosesan citra klasik. Pendekatan ini memungkinkan sistem memberikan hasil awal secara instan setelah citra lesi diunggah, dengan waktu pemrosesan kurang dari satu detik, jauh lebih cepat dibandingkan sistem CNN yang membutuhkan beberapa detik untuk melakukan forward propagation dan klasifikasi akhir.

Tahapan utama sistem prediksi awal meliputi:

1. Pra-Pemrosesan Citra. Mulai dari konversi ruang warna dari BGR ke LAB, perhitungan perbedaan warna global menggunakan indeks ΔE untuk memisahkan area lesi dari kulit normal, proses segmentasi berbasis kontras lokal (region growing) dengan pembatas area “gelap” sebagai dinding region, peningkatan kontras (contrast stretching) dan segmentasi adaptif (Otsu thresholding) untuk membentuk mask lesi utama (wound_mask).



Gambar2 . Hasil Pra-pemrosesan Citra Lesi

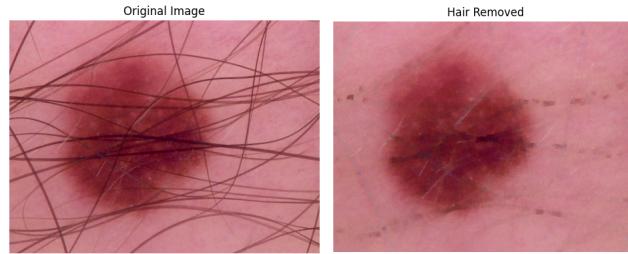
2. Ekstraksi Fitur Lesi. Setelah area lesi teridentifikasi, sistem mengekstraksi empat kategori fitur utama yaitu Geometri dan Morfologi Lesi, Warna (HSV dan LAB) Lesi, Proporsi Warna Penting, dan Variasi Warna Keseluruhan (K-Means clustering pada ruang LAB ($k=3$)).
3. Klasifikasi Penyakit. Fitur hasil ekstraksi kemudian dibandingkan dengan profil statistik referensi tiap penyakit, yang telah dianalisis dari dataset sebanyak 37 gambar dengan tujuh jenis penyakit yaitu Actinic Keratosis (AKIEC), Basal Cell Carcinoma (BCC), Benign Keratosis (BKL), Dermatofibroma (DF), Melanoma (MEL), Nevi (NV), dan Vascular Lesions (VASC).
 - a. Akurasi Keseluruhan : 70,3%
 - b. F1-score (macro) : 0,691
 - c. F1-score (weighted) : 0,688

Hasil yang diperoleh menunjukkan bahwa sistem berhasil mengidentifikasi pola visual khas dari masing-masing penyakit kulit dengan tingkat keakuratan yang baik, dimana actinic keratosis terdeteksi karena memiliki pola warna cerah dengan batas jelas, melanoma berhasil dikenali karena fitur tepi bergerigi dan warna gelap pekat, nevi dan benign lesions menunjukkan variasi tinggi karena heterogenitas klinis dan pencahayaan.

4.2 Pra Pemrosesan Data CNN

Pra-pemrosesan data merupakan tahap penting dalam sistem klasifikasi citra medis karena menentukan kualitas dan keandalan hasil prediksi model deep learning. Pada penelitian ini, proses pra-pemrosesan dilakukan menggunakan OpenCV dan NumPy untuk memastikan setiap citra memiliki tampilan yang seragam dan bebas dari gangguan visual. Langkah pertama adalah penghapusan rambut (hair removal) yang sering menutupi area lesi. Proses ini dilakukan menggunakan metode *morphological black-hat filtering* untuk mendeteksi pola rambut, kemudian

diikuti dengan inpainting berbasis algoritma *Telea* untuk mengisi kembali area yang terhalang tanpa mengubah tekstur kulit di sekitarnya. Sistem juga menghitung rasio area rambut untuk memastikan bahwa gambar yang mengandung lebih dari 15% area tertutup rambut tidak dimasukkan dalam model untuk di analisis. Setelah tahap pembersihan, citra dikonversi ke ruang warna RGB, dinormalisasi ke rentang [0,1], dan diubah ukurannya menjadi 300×300 piksel agar sesuai dengan kebutuhan input model EfficientNet-B3. Selanjutnya dilakukan augmentasi citra, seperti rotasi, flipping, dan perubahan pencahayaan, untuk menambah variasi data dan mengurangi risiko overfitting.



Gambar3 . Contoh Hasil Pra-pemrosesan Data Gambar

4.3 Hasil Pelatihan Model dan Evaluasi Sistem CNN

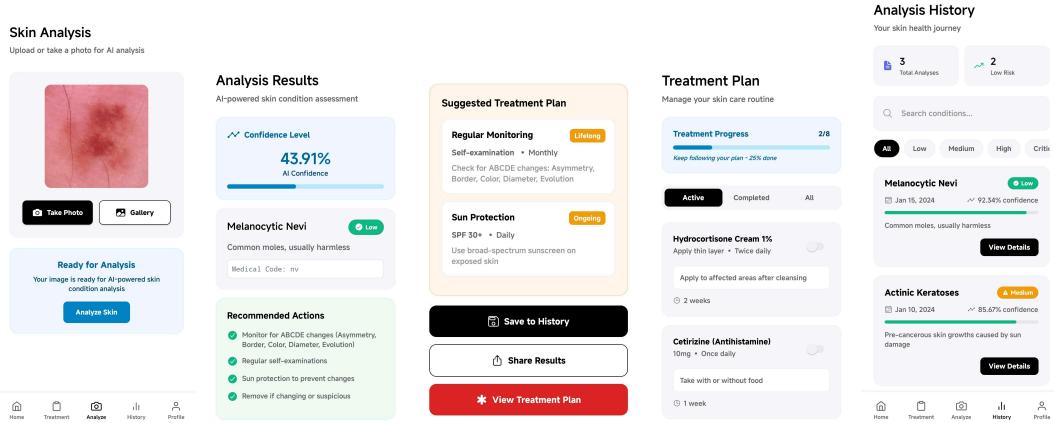
Pelatihan menggunakan arsitektur EfficientNet-B3 yang dimodifikasi menunjukkan performa sangat baik dalam mengklasifikasikan tujuh jenis penyakit kulit pada dataset HAM10000. Dengan penerapan data augmentation, class weighting, dan optimisasi AdamW, model mencapai akurasi di atas 0,98 dan F1-score tinggi pada hampir semua kelas. Kinerja terbaik ditunjukkan oleh kelas melanocytic nevi (NV) dan melanoma (MEL), sementara kelas dengan data terbatas seperti dermatofibroma (DF) dan vascular lesions (VASC) tetap terdeteksi dengan baik berkat penyesuaian bobot dan augmentasi. Tantangan utama masih muncul pada kelas dengan kemiripan visual tinggi serta variasi pencahayaan dan pigmen kulit yang tidak seragam, yang dapat menurunkan akurasi meskipun telah diterapkan normalisasi dan augmentasi pencahayaan.

No	Penyakit Kulit	Akurasi	Presisi	Recall	F1 Score	Specificity	AUROC
1	Melanoma	0,968	0,954	0,945	0,949	0,985	0,965
2	Basal Cell Carcinoma	0,963	0,948	0,958	0,953	0,978	0,968
3	Actinic Keratosis	0,954	0,932	0,941	0,936	0,973	0,957
4	Benign Keratosis	0,963	0,956	0,942	0,949	0,982	0,962
5	Dermatofibroma	0,939	0,918	0,930	0,924	0,987	0,959
6	Melanocytic Nevi	0,966	0,962	0,968	0,965	0,975	0,972
7	Vascular Lesion	0,944	0,935	0,928	0,931	0,986	0,957

Tabel 1. Evaluasi Performa Sistem CNN

Setiap penyakit memiliki karakteristik khas yang membantu proses klasifikasi: MEL berwarna gelap dengan tepi tidak beraturan, BCC kemerahan dengan tepi halus, AKIEC berciri rona terang dengan batas jelas, BKL berwarna homogen, DF coklat-kemerahan, NV simetris dengan variasi warna lembut, dan VASC merah keunguan. Pola ini memungkinkan CNN mengenali fitur visual secara efektif. Secara keseluruhan, model terbukti kuat dan stabil, namun peningkatan kualitas data serta penerapan teknik lanjutan seperti attention mechanism masih diperlukan untuk meningkatkan akurasi dan reliabilitas di masa depan.

4.4 Hasil Interface Aplikasi



Aplikasi Skinlyzer ini berhasil memenuhi delapan prinsip emas Ben Shneiderman mengenai desain antarmuka: Consistency, aplikasi ini mempertahankan pola desain, warna, dan interaksi yang seragam di semua layar. Shortcuts, aksi cepat seperti akses kamera dan tombol pengaturan perawatan mempermudah tugas yang sering dilakukan. Feedback, status pemuatan yang jelas, indikator kemajuan, dan pesan penyelesaian menjaga pengguna tetap terinformasi. Closure, alur kerja yang jelas dari analisis hingga hasil memberikan kepuasan dalam penyelesaian tugas. Error Handling, pesan kesalahan yang membantu dan opsi cadangan yang elegan “membimbing” pengguna melalui masalah. Reversible actions, status perawatan dapat diaktifkan dan dibatalkan dengan mudah. User control, pengguna mengendalikan semua tindakan dari pengambilan gambar hingga pengelolaan perawatan. Memory Load Reduction, data yang disimpan dan organisasi logis meminimalkan kebutuhan memorisasi.

4.5 Kendala

Selain ketidakseimbangan data, variasi warna dan tekstur pada lesi kulit juga menjadi kendala dalam prediksi. CNN cenderung mengandalkan pola warna, tekstur, dan bentuk dalam mendekripsi lesi. Lesi dengan warna yang kontras lebih mudah dikenali, sedangkan lesi yang memiliki warna mirip kulit atau pencahayaan buruk dapat membingungkan model. Fitur seperti asimetri, tepi tidak beraturan, atau pola pigmentasi tetap menjadi indikator penting, namun noise, pencahayaan, dan kondisi citra yang bervariasi dapat menurunkan akurasi. Overfitting dapat terjadi jika akurasi training jauh lebih tinggi dibanding validasi, meskipun penggunaan augmentasi data membantu meningkatkan kemampuan generalisasi.

4.6 Perspektif Klinis dan Perbandingan Penelitian Sebelumnya

Dari perspektif klinis, akurasi tinggi yang dicapai model menunjukkan potensi penggunaannya sebagai alat bantu dalam diagnosis awal penyakit kulit, khususnya dalam membedakan lesi jinak dan ganas. Dengan infrastruktur penyimpanan NEON, setiap prediksi yang dilakukan dapat dilacak dan diaudit. Fitur ini sangat penting dalam konteks medis untuk memenuhi aspek akuntabilitas dan memungkinkan dokter melakukan validasi terhadap hasil klasifikasi sistem. Namun, model ini bukan pengganti pemeriksaan dokter, melainkan sebagai *decision support* yang dapat mempercepat identifikasi awal. Jika dibandingkan dengan penelitian sebelumnya menggunakan arsitektur seperti ResNet atau DenseNet, hasil yang diperoleh cukup kompetitif. Meski demikian, keterbatasan dataset dan strategi augmentasi masih mempengaruhi performa, terutama pada kelas minoritas seperti melanoma, sehingga peningkatan dataset dan teknik augmentasi lebih lanjut diperlukan untuk memaksimalkan kemampuan model.

BAB V. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini berhasil merancang dan mengimplementasikan sistem deteksi dini penyakit kulit berbasis citra digital yang terdiri atas dua komponen utama, yaitu sistem prediksi awal berbasis analisis ΔE dan model klasifikasi berbasis CNN (EfficientNet-B3). Sistem prediksi awal berperan dalam mendeteksi area lesi secara otomatis melalui pendekatan analisis warna dan kontras pada ruang warna CIELAB. Proses ini memungkinkan segmentasi area lesi dengan mempertimbangkan batas alami luka serta perbedaan tonal warna antara kulit sehat dan jaringan patologis. Melalui tahapan ekstraksi fitur geometri, morfologi, serta karakteristik warna, sistem ini mampu memberikan indikasi awal mengenai potensi jenis penyakit kulit sebelum dilakukan klasifikasi akhir oleh CNN.

Model CNN EfficientNet-B3 selanjutnya digunakan untuk mengklasifikasikan jenis penyakit kulit berdasarkan hasil segmentasi dan pra-pemrosesan yang telah dilakukan. Model ini mencapai performa tinggi pada dataset HAM10000 dengan akurasi, precision, recall, dan F1-score yang konsisten di sebagian besar kelas. Kelas melanoma memperoleh hasil terbaik karena memiliki variasi data yang lebih kaya, menunjukkan kemampuan model dalam mengenali pola warna, tekstur, dan bentuk lesi yang kompleks. Penerapan strategi augmentasi dan regularisasi berhasil meningkatkan kemampuan generalisasi model terhadap data baru.

Integrasi antara sistem prediksi awal dan sistem CNN memberikan keuntungan signifikan dalam konteks deteksi dini. Sistem prediksi awal dapat mengidentifikasi area lesi dan memberikan estimasi jenis penyakit secara cepat bahkan sebelum model CNN selesai melakukan klasifikasi penuh, sehingga mempercepat proses diagnosis awal. Pendekatan dua lapis ini menjawab rumusan masalah penelitian:

1. Sistem deteksi dini penyakit kulit berbasis smartphone dengan akurasi tinggi berhasil diwujudkan melalui kombinasi metode ΔE dan CNN.
2. Model CNN yang dioptimalkan dengan pra-pemrosesan berbasis ΔE , augmentasi data, dan ekstraksi fitur warna-morfologi terbukti mampu mengatasi variabilitas citra dermatologis serta meminimalkan kesalahan klasifikasi.

Secara keseluruhan, sistem ini menunjukkan potensi kuat sebagai alat bantu diagnosis berbasis citra dengan kemampuan mendeteksi penyakit kulit secara cepat dan akurat. Meski hasil yang diperoleh cukup baik, penelitian ini memiliki beberapa keterbatasan. Pertama, distribusi data yang tidak seimbang pada kelas tertentu, seperti dermatofibroma (DF) dan vascular lesions (VASC), menyebabkan model kurang optimal dalam mengenali kategori yang jarang muncul. Kedua, faktor eksternal seperti variasi pencahayaan, noise pada citra, serta kemiripan warna antara lesi dan kulit sehat terkadang mengurangi akurasi prediksi. Ketiga, meskipun performa numerik tinggi, model ini belum diuji pada data klinis nyata di luar dataset HAM10000, sehingga generalisasinya masih perlu diverifikasi lebih lanjut. Oleh karena itu, model ini harus dipandang sebagai alat bantu diagnosis yang potensial, namun tetap membutuhkan verifikasi dari tenaga medis profesional sebelum dapat digunakan dalam praktik klinis.

5.2 Saran

Untuk penelitian selanjutnya, disarankan agar dataset diperluas, khususnya pada kelas dengan jumlah data yang lebih sedikit, baik dengan menambah data baru maupun melalui teknik augmentasi

lanjutan seperti generative adversarial networks (GANs). Eksplorasi terhadap arsitektur alternatif seperti ResNet, DenseNet, atau ensemble models juga dapat dilakukan untuk meningkatkan performa secara keseluruhan. Selain itu, pengujian pada data klinis nyata sangat diperlukan agar model dapat divalidasi lebih luas dan teruji pada kondisi yang lebih beragam. Dari sisi implementasi, model ini berpotensi dikembangkan ke dalam aplikasi teledermatologi atau sistem berbasis mobile untuk mendukung deteksi dini kanker kulit. Namun, sangat penting untuk menekankan bahwa sistem ini berfungsi sebagai decision support system, bukan pengganti diagnosis profesional oleh dokter spesialis.

UCAPAN TERIMA KASIH

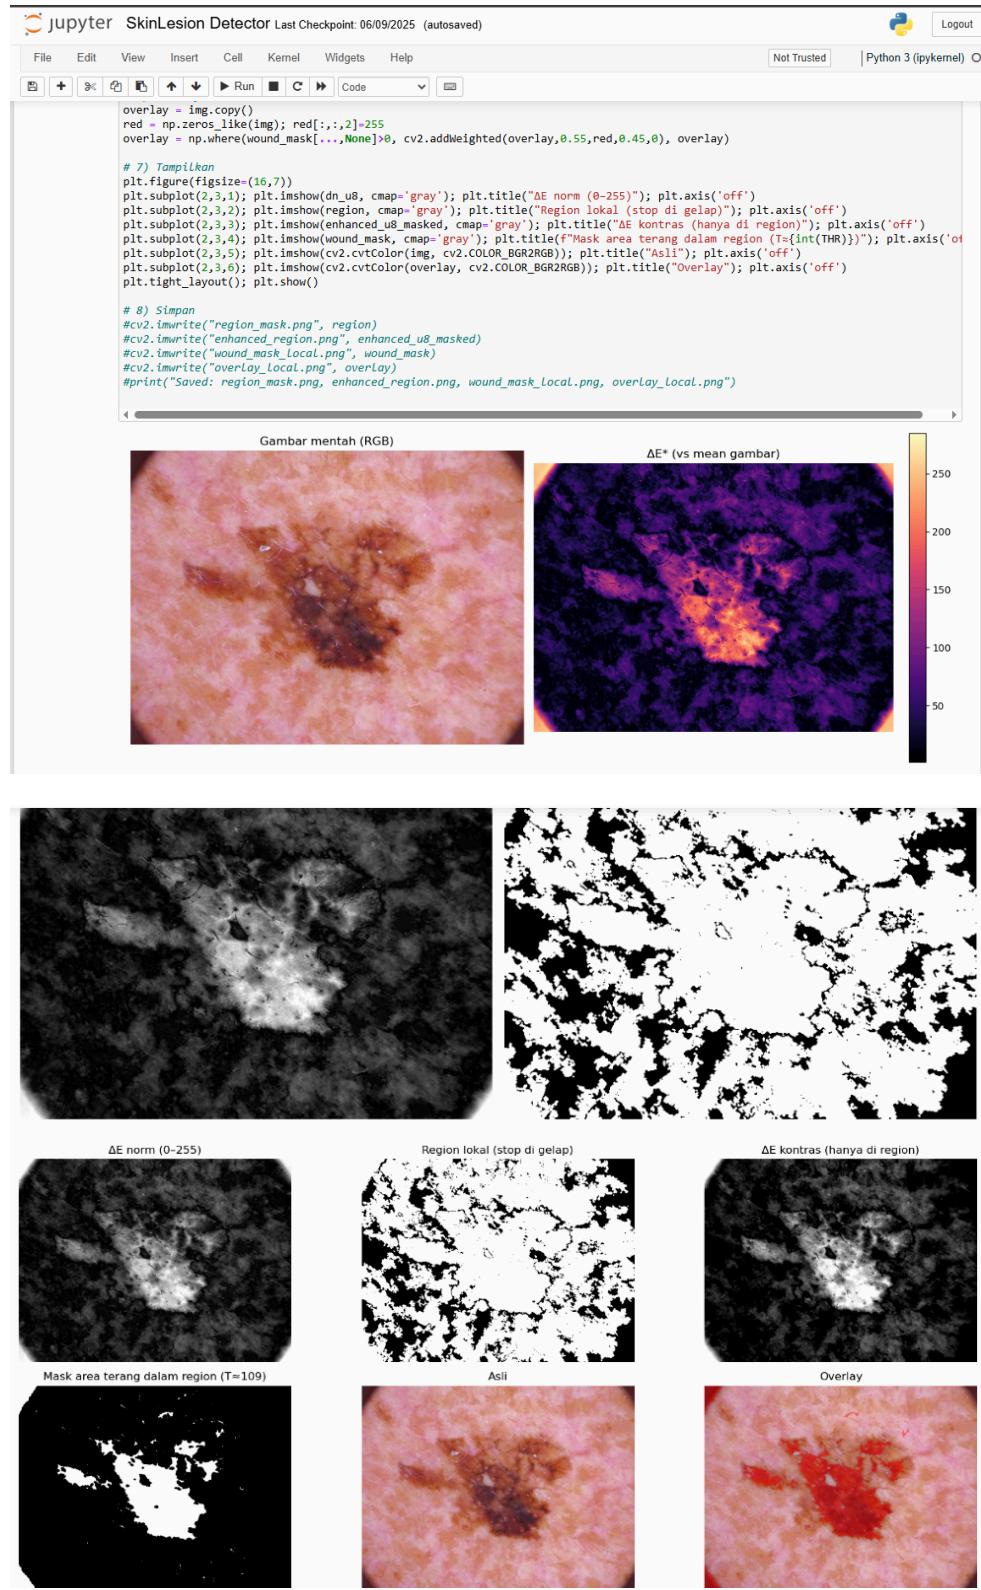
Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan penelitian dan penyusunan laporan ini dengan baik. Penulis juga menyampaikan terima kasih yang sebesar-besarnya kepada berbagai pihak yang telah memberikan dukungan, bimbingan, dan bantuan selama proses penelitian ini berlangsung. Bu Beatrix, selaku dosen pembimbing yang telah memberikan arahan, bimbingan, dan motivasi selama proses penelitian hingga penyusunan laporan ini. Keluarga tercinta, yang senantiasa memberikan doa, dukungan moral, dan motivasi kepada penulis hingga penelitian ini dapat terselesaikan dengan baik.

DAFTAR PUSTAKA

- Ahmed, B., Qadir, M. I., & Ghafoor, S. (2020). Malignant melanoma: Skin cancer-diagnosis, prevention, and treatment. *Critical Reviews in Eukaryotic Gene Expression*, 30(4), 291–297. <https://doi.org/10.1615/critreveukaryotgeneexpr.2020028454>
- Bino, S. V., Unnikrishnan, A., & Balakrishnan, K. (2012). *Gray level co-occurrence matrices: Generalisation and some new features*. arXiv. <https://doi.org/10.48550/arxiv.1205.4831>
- Bodman, M. A., & Al Aboud, A. M. (2025). Melanocytic nevi. In *StatPearls*. StatPearls Publishing. <https://www.ncbi.nlm.nih.gov/books/NBK459175/>
- Brahmbhatt, A. N., Skalski, K. A., & Bhatt, A. A. (2020). Vascular lesions of the head and neck: An update on classification and imaging review. *Insights into Imaging*, 11(1), 19. <https://doi.org/10.1186/s13244-019-0818-3>
- Cui, J., Wang, L., & Ren, W. (2024). Tumor immunotherapy resistance: Revealing the mechanism of PD-1/PD-L1-mediated tumor immune escape. *Biomedicine & Pharmacotherapy*, 171, 116203. <https://doi.org/10.1016/j.biopha.2024.116203>
- Domingues, B., Lopes, J., Soares, P., & Pópolo, H. (2018). Melanoma treatment in review. *ImmunoTargets and Therapy*, 7, 35–49. <https://doi.org/10.2147/ITT.S134842>
- Duarte, A. F., Sousa, M., & Vale, E. (2021). Clinical ABCDE rule for early melanoma detection. *European Journal of Dermatology*, 31(6), 771–778. <https://doi.org/10.1684/ejd.2021.4171>
- Hosna, A., Merry, E., Gyalmo, J., Alom, Z., Aung, Z., & Azim, M. A. (2022). Transfer learning: A friendly introduction. *Journal of Big Data*, 9(1), 102. <https://doi.org/10.1186/s40537-022-00652-w>
- IBM. (2025). *Convolutional neural networks*. <https://www.ibm.com/think/topics/convolutional-neural-networks>
- IBM. (2025). *Image segmentation*. <https://www.ibm.com/think/topics/image-segmentation>
- Larsen, J., Hansen, L. K., Svarer, C., & Ohlsson, M. (2002). Design and regularization of neural networks: The optimal use of a validation set. *Proceedings of the IEEE Signal Processing Society Workshop on Neural Networks for Signal Processing*, 62–71. <https://doi.org/10.1109/NNSP.1996.548336>
- Marr, D., & Hildreth, E. (1980). Theory of edge detection. *Proceedings of the Royal Society of London. Series B, Biological Sciences*, 207(1167), 187–217. <https://doi.org/10.1098/rspb.1980.0020>
- Neon. (2024). *Neon documentation*. Neon Tech, Inc. <https://neon.tech/docs>
- NHS. (2023, April 5). *Symptoms*. NHS UK. <https://www.nhs.uk/conditions/melanoma-skin-cancer/symptoms/>
- Oliphant, T. E. (2007). Python for scientific computing. *Computing in Science & Engineering*, 9(3), 10–20. <https://doi.org/10.1109/MCSE.2007.58>

- Requena, L., & Sangüeza, O. P. (1995). Dermatofibroma. In *Pathology of the Skin*. Elsevier.
- Scholz, J., Klemke, C. D., & Booken, D. (2020). Benign keratoses. *Journal der Deutschen Dermatologischen Gesellschaft*, 18(3), 215–232.
- Sedaghatjoo, Z., Hosseinzadeh, H., & Bigham, B. S. (2024). Local binary pattern (LBP) optimization for feature extraction. arXiv. <https://doi.org/10.48550/arxiv.2407.18665>
- Sekulic, A., Migden, M. R., Oro, A. E., Dirix, L., Lewis, K. D., Hainsworth, J. D., Solomon, J. A., Yoo, S., Arron, S. T., Friedlander, P. A., Marmur, E., Rudin, C. M., Chang, A. L., Low, J. A., Mackey, H. M., Yauch, R. L., Graham, R. A., Reddy, J. C., & Von Hoff, D. D. (2012). Efficacy and safety of vismodegib in advanced basal-cell carcinoma. *New England Journal of Medicine*, 366(23), 2171–2179. <https://doi.org/10.1056/NEJMoa1113713>
- Sharma, B., & Nayyer, R. (2015). Use and analysis of color models in image processing. *International Journal of Advances in Scientific Research*, 1(8), 329–332.
<https://doi.org/10.7439/ijasr.v1i8.2460>
- Siegel, J. A., Totonchy, M. B., & Damsky, W. (2020). Actinic keratoses and intraepithelial carcinoma. *Dermatologic Clinics*, 38(4), 427–436.
- Tableau. (2025). *Guide to data cleaning: Definition, benefits, components, and how to clean your data*. <https://www.tableau.com/learn/articles/what-is-data-cleaning>
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning*, 6105–6114.
<https://proceedings.mlr.press/v97/tan19a.html>
- Terashima, N. (2002). Computer vision. In *Advanced Intelligent Environments*. Springer.
- Yang, D., Li, M., & Wei, Z. (2022). An overview of edge and object contour detection. *Neurocomputing*, 488, 470–493. <https://doi.org/10.1016/j.neucom.2022.02.079>
- Zhou, Z. (2021). *Machine learning*. Springer. <https://doi.org/10.1007/978-981-15-1967-3>

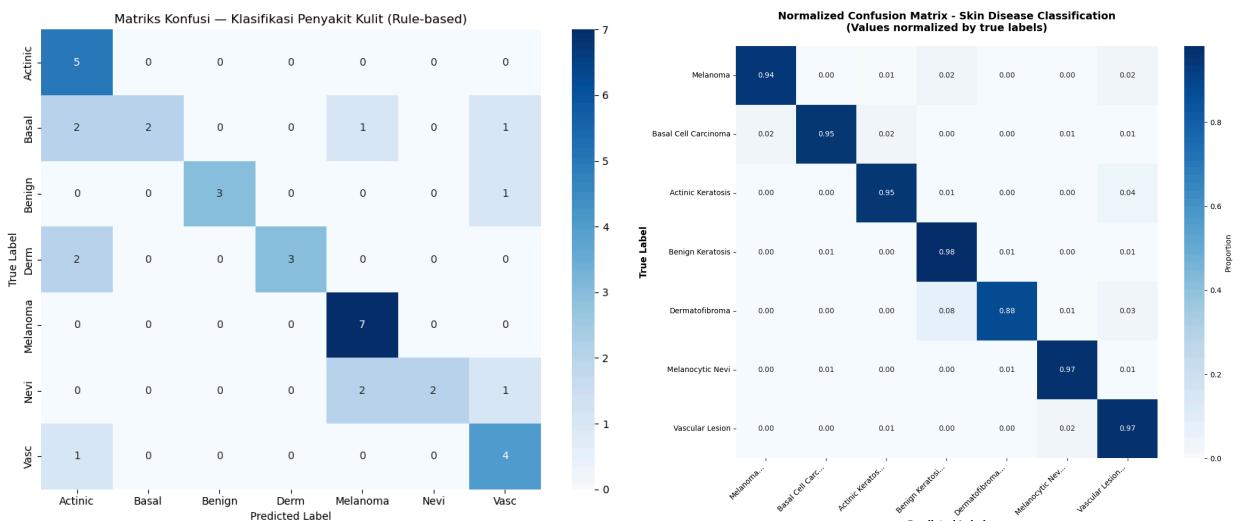
Lampiran



HASIL EVALUASI KLASIFIKASI
 Akurasi Keseluruhan : 0.703
 F1-score (macro) : 0.691
 F1-score (weighted) : 0.688

Laporan Detail per Penyakit:

	precision	recall	f1-score	support
Actinic	0.500	1.000	0.667	5
Basal	1.000	0.333	0.500	6
Benign	1.000	0.750	0.857	4
Derm	1.000	0.600	0.750	5
Melanoma	0.700	1.000	0.824	7
Nevi	1.000	0.400	0.571	5
Vasc	0.571	0.800	0.667	5
accuracy			0.703	37
macro avg	0.824	0.698	0.691	37
weighted avg	0.818	0.703	0.688	37



```

df = pd.read_csv('metabagged.csv')
df['dx'].isin(label_map.keys()).copy() # guard against stray labels
df['label'] = df['dx'].map(label_map)
df['path'] = df['image_id'].apply(lambda x: os.path.join(image_dir, f'{x}.jpg'))

# Filter rows whose image file actually exists
df = df[df['path'].apply(os.path.exists)].reset_index(drop=True)

# Stratified split (train/val)
train_df, val_df = train_test_split(
    df, test_size=0.2, stratify=df['label'], random_state=42
)

# -----
# DATASET
# -----
class SkinDataset(Dataset):
    def __init__(self, dataframe, transform=None):
        self.df = dataframe.reset_index(drop=True)
        self.transform = transform

    def __len__(self):
        return len(self.df)

    def __getitem__(self, idx):
        row = self.df.iloc[idx]
        img = Image.open(row['path']).convert("RGB")
        if self.transform:
            img = self.transform(img)
        label = int(row['label'])
        return img, label
  
```